패션커머스 고객 TPO*에 맞는 맞춤추천 시스템 개발

*TPO(Time, Place, Occasion의 약자)

김현재 21.3.16

목차

- 프로젝트 배경
- 데이터 소개
- 추천모델 주요 개념 소개
- 본 프로젝트 가설, 분석 모델, 검정 결과
- 결과 요약 및 향후 보완할 점

왜? 고객의 TPO를 잡아야 할까요?

- 잘 나가는 '패션 유튜버'도, 인스타그래머도 고객을 사로잡는 방법 'TPO별 룩(look)&코디 제안'!

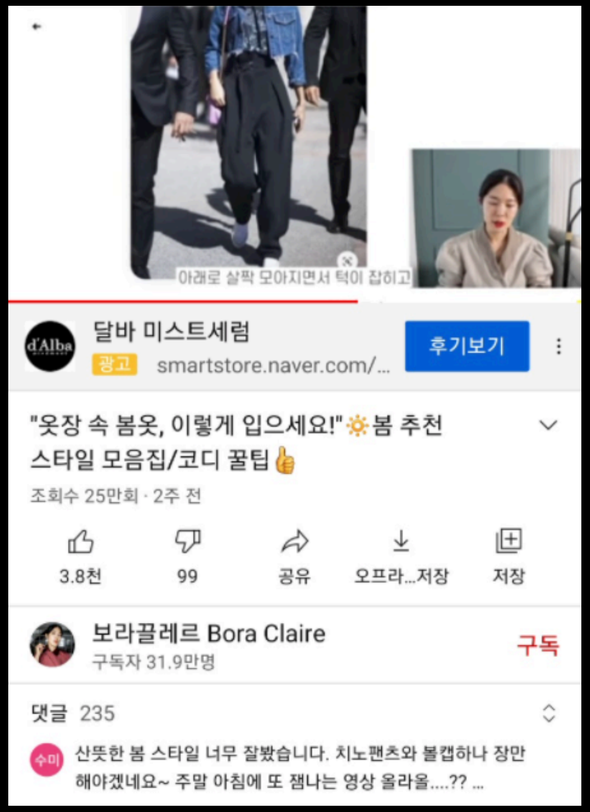

고객 TPO별 다양한 룩을 제안하여,
추가 구매 전환 기회가 많은 곳

데이터 소개 - ‘RentTheRunway’ 데이터

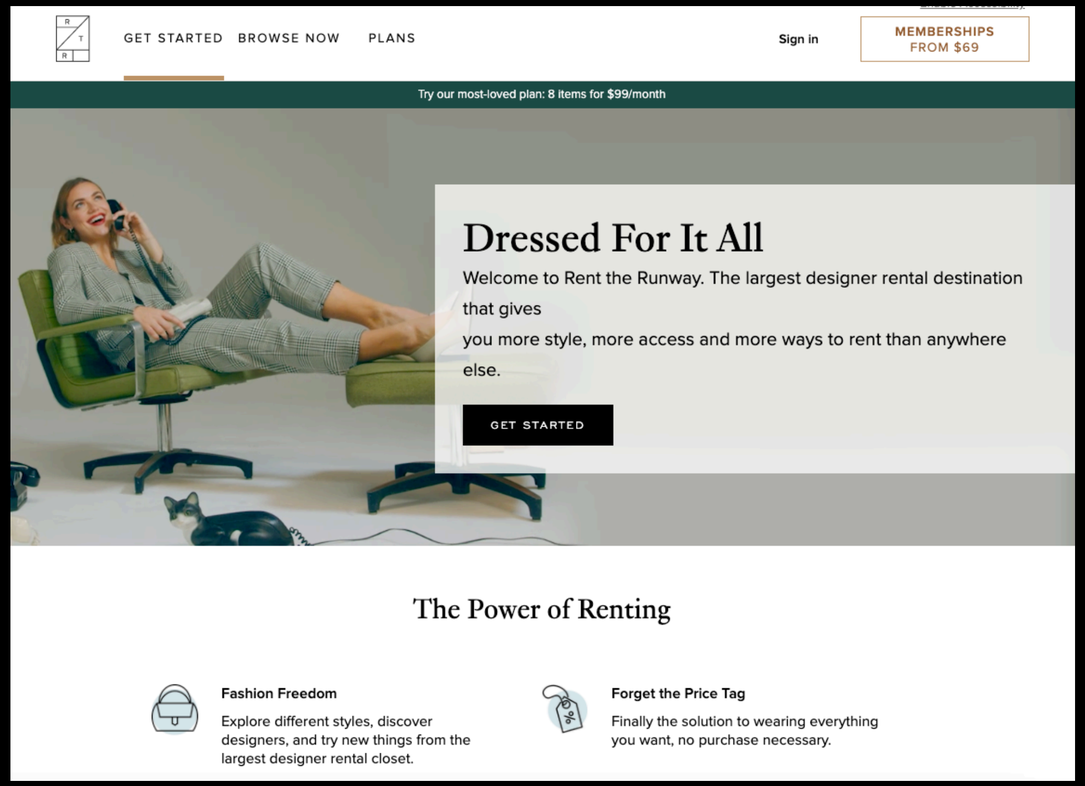

< 데이터 형태 >

- Number of customers: 105,508
- Number of products: 5,850
- Number of transactions: 192,544

< 데이터 특성 >

- user_id: a unique id for the customer
- item_id: unique product id
- rating: rating for the product
- rating_average : popularity를 측정하기 위한 것으로 아이템별 rating 평균값.
- weight: weight measurement of customer
- rented for: purpose clothing was rented for => TPO 데이터로 사용
- body type: body type of customer
- review_text: review given by the customer
- review_summary: summary of the review
- size: the standardized size of the product
- age: age of the customer
- category: the category of the product
- bust size: bust measurement of customer
- height: height of the customer
- fit: fit feedback
- review_date: date when the review was written

※출처: 캐글(Kaggle)에 공개된 ‘RentTheRunway’ 여성 의류쇼핑몰 데이터셋
https://www.kaggle.com/rmisra/clothing-fit-dataset-for-size-recommendation

추천모델 주요 개념 소개 - 모델의 유형

1. 콘텐츠기반 필터링

(content based filtering)

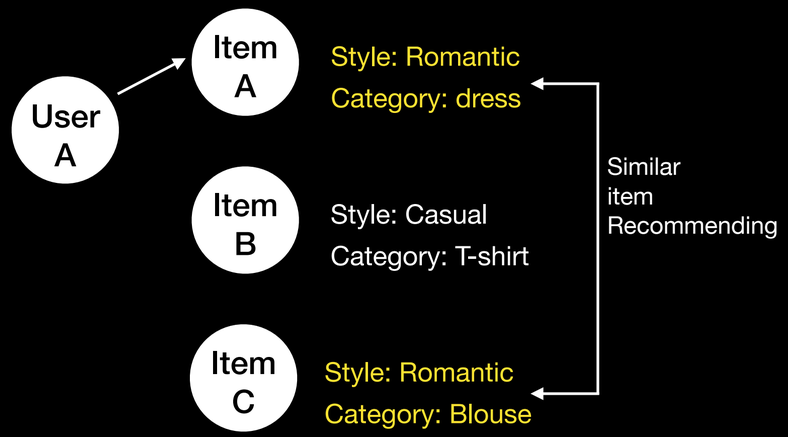

- 장점: 모델이 단순하고 빠름.
- 단점: 식상한 컨텐츠 추천이 될 수 있음.

2. 협업필터링

(CF:Collaborative Filtering)

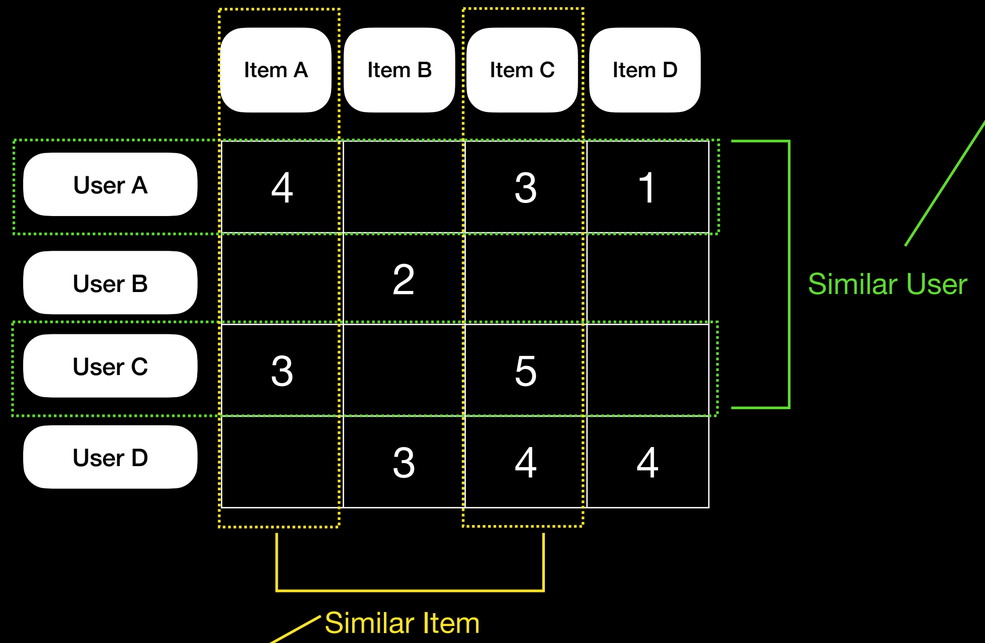

<item-to-item>

- 장점: 아이템이 매우 많은 경우, 유저베이스에 비하여 더 빠르고 안정적.
- 단점: 특정 아이템을 좋아한다고 해당 아이템과 연관된 모든 아이템을 좋아하지 않을 수 있고, 식상한 추천이 될 수 있음.

<user-to-user>

- 장점: 비슷한 유저 그룹이 소비한 다른 컨텐츠를 추천하기 때문에, 소비자 특성이 잘 분류되는 시장에서 만족도 높은 컨텐츠를 추천.
- 단점: 위 모델에서는 오직 평점을 기준으로 유사그룹을 측정한다는 점. 평점 이외 다른 요소를 고려하지 않음.

추천모델 주요 개념 소개 - 모델의 유형

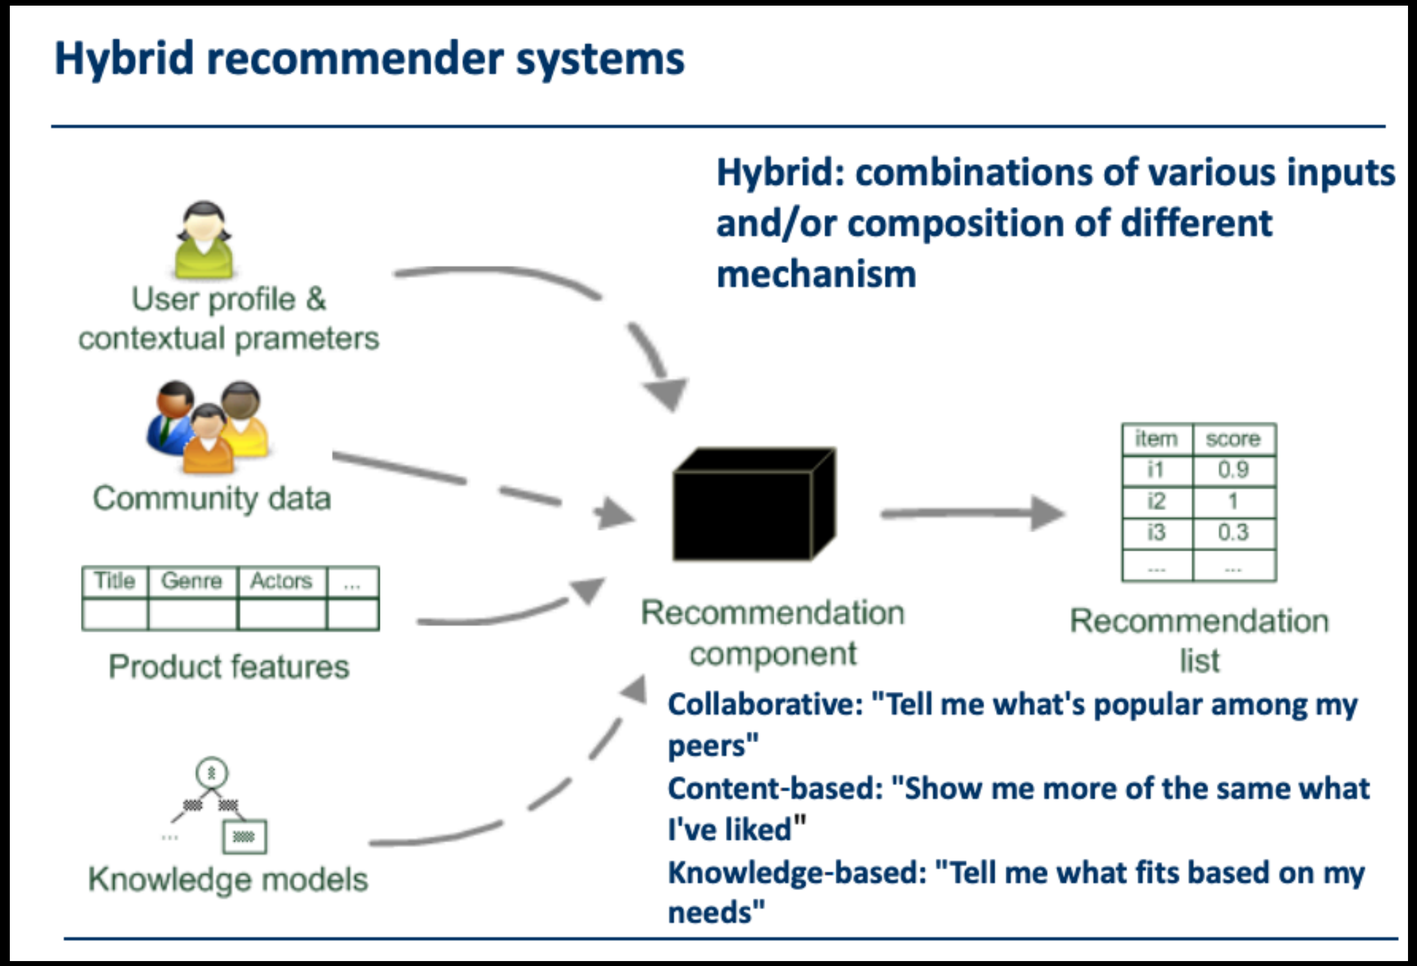

3. 하이브리드 추천 모델

(Hybrid recommendation)

- 장점: 유저의 평점 데이터로만 추천하는 것이 아니라, 유저와 아이템의 다양한 다른 특성(ex. Age, style needs, item-color/design/fit/category, etc.) 을 고려하여 추천하기 때문에 '유사도가 있으면서, 신선도가 있는 추천이 가능'
- 단점: 모델 구현이 복잡하고, 해당 시장의 특성에 따라 적절한 솔루션을 찾아야 한다는 점.

※출처: https://www.math.uci.edu/icamp/courses/math77b/lecture_12w/pdfs/Chapter%2005%20-%20Hybrid%20recommendation%20approaches.pdf

추천모델 주요 개념 소개 - 평가지표

1. 모델의 성능지표

RMSE(Root Mean Square Error)

$$\mathrm{RMSE} = \sqrt{\frac{1}{|\hat{R}|}\sum_{\hat{r}_{ui}\in\hat{R}}(r_{ui}-\hat{r}_{ui})^2}.$$

MAE(Mean Absolute Error)

$$\mathrm{MAE} = \frac{1}{|\hat{R}|}\sum_{\hat{r}_{ui}\in\hat{R}}|r_{ui}-\hat{r}_{ui}|$$

<RMSE, MAE의 의미>

- 예측 평점과 실제 평점 사이의 오차(손실)
- 크기가 작을수록 모델 예측 성능이 좋음을 의미.
- RMSE는 오차에 대해서 MAE보다 더 큰 값으로 보여주기 때문에,

일반적인 머신러닝 모델에서 성능개선을 더 정확하게 해야 할 때 사용.

2. 추천목록의 평가지표

$$\mathrm{Precision@k} = \frac{|\{\text{Recommended items that are relevant}\}|}{|\{\text{Recommended items}\}|}$$

$$\mathrm{Recall@k} = \frac{|\{\text{Recommended items that are relevant}\}|}{|\{\text{Relevant items}\}|}$$

Precision(정밀도) :

추천된 K개의 아이템 중 유사도가 높은 아이템들의 비중.

(전체 추천목록 내에 유사도가 있는 추천 아이템들이 얼마나 되는지 측정,

추천목록 내 유사도 비중을 높일 때 정밀도를 높이면 됨.)

Recall(재현율):

유사도가 높은 아이템들 중 추천된 K개의 아이템들의 유사도 비중

(전체 추천목록 자체가 얼마나 유사도가 높은지 측정,

추천할 때마다 추천목록의 전체 유사도를 유지하고 싶을 때 사용.)

본 프로젝트 가설, 분석 방법 소개

■ (가설1) 아이템 기반 협업필터링 추천모델보다, SVD 협업필터링 모델의 성능이 더 높을 것이고, 가장 성능이 좋은 모델로 추천 목록을 고른다.

=> 분석방법: 아이템 기반 협업필터링 추천모델과 SVD 협업필터링 모델의 RMSE, MAE 수치 비교.

■ (가설2) 협업필터링의 추천모델 목록보다, 하이브리드 추천모델(고객의 TPO,Category,popularity 등을 추가한)의 추천목록의 순위평가지표가 더 높을 것이다.

=> 분석방법: 아이템 기반 협업필터링 모델과 SVD 협업필터링 모델의 RMSE, MAE 수치 비교.

가설(1) 검정결과

■ (가설1) 아이템 기반 협업필터링 추천모델보다, SVD 협업필터링 모델의 성능이 더 높을 것이다.

=> 분석방법: 아이템 기반 협업필터링 모델과 SVD 협업필터링 모델의 RMSE, MAE 수치 비교.

	Algorithm	test_rmse	test_mae
0	KnnBaseline(item-based)	0.718082	0.564715
1	KnnBaseline(user-based)	0.716891	0.563900
2	SVD(CF)	0.718168	0.560152
3	SVDpp(CF)	0.716266	0.556810
4	gridsearch(SVDpp)	0.715593	0.564648
5	Hybrid(CF+CBF)	0.717355	0.561553

- 사용한 모듈: Surprise (python library)
- KnnBaseline(item-based)모델: 기본 협업필터링 알고리즘 +Baseline을 추가하여 사용자별 평점 편향을 줄인 모델
- SVD모델: 특이값 분해(SVD)방식으로 계산한 협업필터링 모델
- SVDpp모델: SVD모델에 암시적 평점을 고려한 모델.
- Hybrid모델: SVDpp모델과 KnnBaseline을 4:6비중으로 가중평균합하여 rmse와 mae를 계산, 고객TPO특성이 합쳐진 모델.
- 5가지 알고리즘 중 근소한 차이로 SVDpp **모델 성능이 가장 우수. 다만, 차이가 너무 근소하여 SVDpp모델의 성능 증명이 명확하다고 보기 어려워보임. 데이터의 Sparsity가 높을 경우 SVD, SVDpp의 성능이 기대보다 높게 나오지 않는다는 한계점을 배움.**

가설(2) 검정결과

■ (가설2) 협업필터링의 추천모델 목록보다, 하이브리드 추천모델(고객의 TPO,Category,popularity 등을 추가한)의 추천목록의 순위평가지표가 더 높을 것이다.

	Algorithm	test_rmse	test_mae	Precision	recall
0	KnnBaseline(item-based)	0.718082	0.564715	0.931839	0.943002
1	KnnBaseline(user-based)	0.716891	0.563900	0.932373	0.943399
2	SVD(CF)	0.718168	0.560152	0.931827	0.942827
3	SVDpp(CF)	0.716266	0.556810	0.930189	0.940228
4	gridsearch(SVDpp)	0.715593	0.564648	0.932217	0.943309
5	Hybrid(CF+CBF)	0.717355	0.561553	0.931179	0.941893

- Recall: 수치가 높을수록 유사도 높은 아이템들이 추천목록에 얼만큼 존재하는지 보여줌
- 근소한 차이로 KnnBaseline(user-based) 모델과 gridsearchCV로 조정한 SVDpp모델이 Recall값이 가장 높으나, 수치 차이가 매우 근소하다는 한계점.

Hybrid 추천목록의 장점

Hybrid 추천 목록 결과 (testset user = 817402)

	item_id	est	Model	category	TPO
2	543189	4.772779	Popularity(rating_average)	[gown, gown, gown, gown, gown, gown, gown, gow...	[wedding, wedding, formal affair, formal affai...
3	633179	4.752781	Popularity(rating_average)	[maxi, maxi, maxi, maxi, maxi, maxi, maxi, max...	[wedding, party, wedding, party, formal affair...
1	2337876	4.731897	Popularity(rating_average)	[skirt, skirt, skirt, skirt, skirt]	[other, party, party, other, party]
6	2276741	4.728079	Popularity(rating_average)	[jumpsuit, jumpsuit, jumpsuit]	[other, party, other]
4	675264	4.715891	Popularity(rating_average)	[gown, gown, gown, gown, gown]	[other, wedding, formal affair, wedding, forma...
9	708493	4.680326	Popularity(rating_average)	[dress, dress, dress]	[other, everyday, work]
0	330893	4.661841	Popularity(rating_average)	[dress, dress]	[party, other]
5	1011971	4.640780	Popularity(rating_average)	[dress, dress]	[other, formal affair]
7	328677	4.631116	Popularity(rating_average)	[dress, dress, dress]	[other, party, party]
8	1285191	4.589043	Popularity(rating_average)	[dress]	[other]

기존 추천목록에서는 '아이템' 추천목록만 확인 가능하다면,
하이브리드 모델의 결과는 아이템별 카테고리와 TPO를 확인할 수 있어 더 다양한 추천으로 이어질 수 있다는 장점.
추천알고리즘에서 '신선도', '다양성' 등이 중요한 이슈인만큼 모델의 성능차이가 근소하다면 하이브리드 모델을 사용하는 것이
다양성과 개인화 니즈를 만족시킬 수 있는 모델에 가까울 것으로 기대.

결론 요약 및 향후 보완하면 좋을 점

[결론 요약]

1. 가설1 검정결과 : 아이템기반 모델(Knn-baseline_item-based)보다 SVDpp모델의 RMSE수치가 근소하게 낮음(성능이 좋음)

- KnnBaseline(item-based) RMSE: 0.718082 > SVDpp RMSE: 0.716266

==> 차이가 너무 근소하여 가설검정에 유의미하다고 보기 어려울 수 있다는 한계점.

2. 가설2 검정결과: KnnBaseline(user-based)모델과 gridsearchCV로 조정한 SVDpp모델이 Recall값이 가장 높음.

- KnnBaseline(item-based) recall: 0.943002 < SVDpp(gridsearchCV) recall: 0.943309

==> 차이가 너무 근소하여 가설검정에 유의미하다고 보기 어려울 수 있다는 한계점.

[향후 보완하면 좋을 점]

1. 유저의 구매고려사항에 대한 데이터 확보(해당 아이템을 살 때 고려하는 점의 우선순위 등)
2. 추천 시스템에 대한 유저의 취향 파악 (신선도 vs 유사도 비중을 어느 정도로 좋아하는지 등)
3. 실제 유저가 반응한 유저행동데이터(구매/클릭/체험한 시간 등) 를 고려한 추천

참고자료

<추천모델의 개념>

“Build a Recommendation Engine With Collaborative Filtering”
https://realpython.com/build-recommendation-engine-collaborative-filtering/

“Hybrid recommendation approach”
https://www.math.uci.edu/icamp/courses/math77b/lecture_12w/pdfs/Chapter%2005%20-%20Hybrid%20recommendation%20approaches.pdf

"Survey on Collaborative Filtering, Content-based Filtering and Hybrid Recommendation System"
https://bit.ly/3tenCml

<코드구현 참고자료>

Python Surprise 라이브러리
https://surprise.readthedocs.io/en/stable/index.html

hybrid_model_CF and Latent factor models
https://github.com/prakruti-joshi/Movie-Recommendation-System/blob/master/Code/hybrid_model.ipynb